

概率论与数理统计考研核心公式

强化版：变形与推导

考研复习资料

2026 年 6 月 17 日

使用说明

本手册聚焦考研中**公式的变形形式与关键推导过程**，帮助考生理解公式本质、应对灵活考题。每个专题包含：**变形形式**（考研常考的等价写法与推广）、**推导过程**（理解公式来源）、**考点提示**（命题角度与解题技巧）。建议在掌握全公式版和挖空版后使用本册进行强化提升。

目录

1 随机事件与概率	3
1.1 加法公式的多种变形	3
1.2 全概率公式与贝叶斯公式的变形	3
1.3 独立性的等价条件与反例	4
2 随机变量及其分布	5
2.1 二项分布的近似与变形	5
2.2 正态分布的线性变换与可加性	5
2.3 随机变量函数分布的公式法推导	6
3 数字特征	6
3.1 期望与方差的性质汇总	7
3.2 协方差与相关系数的变形	8
3.3 随机变量和的期望与方差	8
4 大数定律与中心极限定理	9
4.1 切比雪夫不等式的应用与变形	9
4.2 中心极限定理的标准化变形	10
5 数理统计的基本概念	11
5.1 三大抽样分布的构造与性质	11
5.2 样本方差的两种定义对比	12

6	参数估计	13
6.1	矩估计的求解流程	13
6.2	最大似然估计的求解流程	14
6.3	区间估计的构造原理	14
7	假设检验	15
7.1	假设检验与区间估计的对偶关系	15
7.2	单侧检验与双侧检验的拒绝域	16
7.3	两类错误与功效函数	17
8	综合应用与跨模块联系	17
8.1	正态分布在各模块的贯穿	17
8.2	独立同分布条件的统一理解	18
8.3	考研高频题型与公式对应	18

第 1 章 随机事件与概率

1.1 加法公式的多种变形

加法公式的一般形式与变形

两事件:

$$P(A \cup B) = P(A) + P(B) - P(AB).$$

三事件:

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC).$$

变形 1 (用对立事件):

$$P(A \cup B) = 1 - P(\bar{A} \bar{B}) = 1 - P(\overline{A \cup B}).$$

变形 2 (条件概率形式):

$$P(A \cup B) = P(A) + P(B) - P(A)P(B | A) \quad (P(A) > 0).$$

变形 3 (差事件):

$$P(A - B) = P(A) - P(AB) = P(A\bar{B}).$$

三事件加法公式推导

利用 $A \cup B \cup C = (A \cup B) \cup C$ 及两事件加法公式:

$$\begin{aligned} P(A \cup B \cup C) &= P(A \cup B) + P(C) - P((A \cup B)C) \\ &= P(A) + P(B) - P(AB) + P(C) - P(AC \cup BC) \\ &= P(A) + P(B) + P(C) - P(AB) - [P(AC) + P(BC) - P(ABC)] \\ &= P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC). \end{aligned}$$

规律: 奇数个事件交的概率取正号, 偶数个取负号 (容斥原理)。

考点提示

考研常考“至少发生一个”的概率, 优先用对立事件 $P(A \cup B \cup C) = 1 - P(\bar{A}\bar{B}\bar{C})$ 简化计算; 当事件独立时, $P(\bar{A}\bar{B}\bar{C}) = P(\bar{A})P(\bar{B})P(\bar{C})$ 尤为简便。

1.2 全概率公式与贝叶斯公式的变形

完备事件组的常见选取

变形 1 (二划分): 取 A 与 $\bar{A}$ 作划分:

$$P(B) = P(A)P(B | A) + P(\bar{A})P(B | \bar{A}).$$

变形 2 (多阶段划分): 若试验分两阶段, 第一阶段结果 $A_1, \dots, A_n$ 为划分, 第二阶段结果 B

的概率用全概率公式。**变形 3 (贝叶斯的”后验”形式):**

$$P(A_k | B) = \frac{P(A_k)P(B | A_k)}{P(B)}, \quad P(B) = \sum_i P(A_i)P(B | A_i).$$

变形 4 (连续型全概率): 若 X 有密度 $f(x)$, $Y | X = x \sim$ 条件密度 $f_{Y|X}(y|x)$, 则

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{Y|X}(y|x) f_X(x) dx.$$

贝叶斯公式推导

由条件概率定义:

$$P(A_k | B) = \frac{P(A_k B)}{P(B)}.$$

分子用乘法公式: $P(A_k B) = P(A_k)P(B | A_k)$; 分母用全概率公式: $P(B) = \sum_{i=1}^n P(A_i)P(B | A_i)$. 代入即得贝叶斯公式。

解题模板

全概率/贝叶斯题型四步法:

1. 识别”原因”(完备事件组 $A_1, \dots, A_n$) 与”结果”(事件 B);
2. 计算/给出先验概率 $P(A_i)$ 和条件概率 $P(B | A_i)$;
3. 全概率: $P(B) = \sum P(A_i)P(B | A_i)$;
4. 贝叶斯: $P(A_k | B) = \frac{P(A_k)P(B | A_k)}{P(B)}$ 。

1.3 独立性的等价条件与反例

独立性的等价表述

A 与 B 独立 $\iff$ 以下任一成立:

1. $P(AB) = P(A)P(B)$;
2. $P(A | B) = P(A)$ ($P(B) > 0$);
3. $P(A | \bar{B}) = P(A)$ ($P(\bar{B}) > 0$);
4. $P(A | B) = P(A | \bar{B})$ ($P(B)P(\bar{B}) > 0$);
5. A 与 $\bar{B}$ 独立; $\bar{A}$ 与 B 独立; $\bar{A}$ 与 $\bar{B}$ 独立。

经典反例: 两两独立但不相互独立

掷一枚均匀骰子, $A = \{1, 2, 3, 4\}$, $B = \{1, 2, 5, 6\}$, $C = \{1, 3, 5, 7\}$ (此处用 8 面骰)。可验证 $P(AB) = P(A)P(B)$, $P(AC) = P(A)P(C)$, $P(BC) = P(B)P(C)$ (两两独立), 但 $P(ABC) \neq P(A)P(B)P(C)$ (不相互独立)。**结论:** 两两独立 $\nRightarrow$ 相互独立。

第 2 章 随机变量及其分布

2.1 二项分布的近似与变形

二项分布的两种近似

泊松近似 (n 大 p 小): 当 $n \geq 20$, $p \leq 0.05$, $np = \lambda$ 适中时:

$$\binom{n}{k} p^k (1-p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!}, \quad \lambda = np.$$

正态近似 (n 大 p 适中): 当 n 大时 (棣莫弗-拉普拉斯):

$$Y_n \sim B(n, p) \Rightarrow \frac{Y_n - np}{\sqrt{np(1-p)}} \sim N(0, 1).$$

变形 (标准化计算):

$$P(a \leq Y_n \leq b) \approx \Phi\left(\frac{b + 0.5 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - 0.5 - np}{\sqrt{np(1-p)}}\right).$$

连续性修正

用正态近似二项分布时, 离散值用 ± 0.5 修正 (连续性修正), 提高精度。例如 $P(Y_n = k) \approx P(k - 0.5 < Y_n < k + 0.5)$ 。

2.2 正态分布的线性变换与可加性

正态分布的性质

线性变换: 若 $X \sim N(\mu, \sigma^2)$, 则 $aX + b \sim N(a\mu + b, a^2\sigma^2)$ ($a \neq 0$)。 **标准化:** $Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$ 。

独立正态可加性: 若 $X_i \sim N(\mu_i, \sigma_i^2)$ 独立, 则

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right).$$

线性组合: $Y = \sum c_i X_i \sim N(\sum c_i \mu_i, \sum c_i^2 \sigma_i^2)$ (独立时)。

线性变换推导

设 $X \sim N(\mu, \sigma^2)$, $Y = aX + b$ ($a > 0$), 用分布函数法:

$$F_Y(y) = P(aX + b \leq y) = P\left(X \leq \frac{y - b}{a}\right) = \Phi\left(\frac{(y - b)/a - \mu}{\sigma}\right) = \Phi\left(\frac{y - (a\mu + b)}{a\sigma}\right).$$

求导得 $f_Y(y) = \frac{1}{a\sigma} \varphi\left(\frac{y - (a\mu + b)}{a\sigma}\right)$, 即 $Y \sim N(a\mu + b, a^2\sigma^2)$ 。 $a < 0$ 时类似 (注意绝对值)。

3σ 原则与查表技巧

- $P(|X - \mu| < \sigma) \approx 0.6827$, $P(|X - \mu| < 2\sigma) \approx 0.9545$, $P(|X - \mu| < 3\sigma) \approx 0.9973$;
- $\Phi(-x) = 1 - \Phi(x)$ (对称性);

- $P(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right);$
- $P(X > x) = 1 - \Phi\left(\frac{x - \mu}{\sigma}\right) = \Phi\left(\frac{\mu - x}{\sigma}\right)。$

2.3 随机变量函数分布的公式法推导

公式法 $f_Y(y) = f_X(h(y))|h'(y)|$ 的推导

设 $Y = g(X)$, g 严格单调递增、可导, 反函数 $x = h(y)$ 。

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = P(X \leq h(y)) = F_X(h(y)).$$

求导 (链式法则):

$$f_Y(y) = F'_Y(y) = f_X(h(y)) \cdot h'(y).$$

若 g 严格单调递减, 则 $P(g(X) \leq y) = P(X \geq h(y)) = 1 - F_X(h(y))$, 求导得 $f_Y(y) = -f_X(h(y))h'(y)$ 。由于递减时 $h'(y) < 0$, 故 $-h'(y) = |h'(y)|$ 。合并两种情况:

$$f_Y(y) = f_X(h(y)) \cdot |h'(y)|.$$

分段单调的处理

若 $g(x)$ 在区间 $I_1, I_2, \dots$ 上分别单调, 反函数 $h_1(y), h_2(y), \dots$, 则

$$f_Y(y) = \sum_j f_X(h_j(y)) \cdot |h'_j(y)|.$$

经典例: $Y = X^2$, $X \sim N(0, 1)$, 则 $f_Y(y) = \frac{1}{\sqrt{2\pi y}} e^{-y/2}$, $y > 0$ (自由度为 1 的 χ^2 分布)。

常见函数的密度

- $Y = aX + b$ ($a \neq 0$): $f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y - b}{a}\right);$
- $Y = X^2$ (X 对称于 0): $f_Y(y) = \frac{1}{\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})], y > 0;$
- $Y = e^X$: $f_Y(y) = f_X(\ln y) \cdot \frac{1}{y}, y > 0。$

第 3 章 数字特征

3.1 期望与方差的性质汇总

期望与方差的运算性质

期望的线性性 (无需独立):

$$E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i E(X_i).$$

乘积的期望:

$$E(XY) = E(X)E(Y) + \text{Cov}(X, Y).$$

独立时 $\text{Cov}(X, Y) = 0$, 故 $E(XY) = E(X)E(Y)$ 。

方差的可加性 (需独立或已知协方差):

$$D\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 D(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j).$$

独立时协方差项为 0, 简化为 $D(\sum a_i X_i) = \sum a_i^2 D(X_i)$ 。

方差公式 $D(X) = E(X^2) - [E(X)]^2$ 的推导

$$\begin{aligned} D(X) &= E[(X - E(X))^2] = E[X^2 - 2XE(X) + (E(X))^2] \\ &= E(X^2) - 2E(X) \cdot E(X) + [E(X)]^2 \quad (\text{线性性}) \\ &= E(X^2) - [E(X)]^2. \end{aligned}$$

关键: $E(X)$ 是常数, 可提出期望符号; $E[E(X)] = E(X)$ 。

常见分布的期望方差速查

分布	记号	$E(X)$	$D(X)$
0-1 分布	$B(1, p)$	p	$p(1 - p)$
二项分布	$B(n, p)$	np	$np(1 - p)$
泊松分布	$P(\lambda)$	λ	λ
均匀分布	$U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态分布	$N(\mu, \sigma^2)$	μ	σ^2
指数分布	$\text{Exp}(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
几何分布	$\text{Geo}(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$

3.2 协方差与相关系数的变形

协方差与相关系数的等价形式

协方差的变形:

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) = E[(X - E(X))(Y - E(Y))].$$

相关系数的变形:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}} = \frac{E(XY) - E(X)E(Y)}{\sqrt{D(X)}\sqrt{D(Y)}}.$$

标准化变量的协方差: 令 $X^* = \frac{X - E(X)}{\sqrt{D(X)}}$, $Y^* = \frac{Y - E(Y)}{\sqrt{D(Y)}}$, 则

$$\rho_{XY} = \text{Cov}(X^*, Y^*) = E(X^*Y^*).$$

方差与协方差的关系:

$$D(X \pm Y) = D(X) + D(Y) \pm 2\text{Cov}(X, Y).$$

$|\rho| \leq 1$ 的证明 (柯西-施瓦茨不等式)

对任意实数 t , 令 $Z = t(X - E(X)) + (Y - E(Y))$, 则 $D(Z) \geq 0$:

$$D(Z) = t^2 D(X) + 2t \text{Cov}(X, Y) + D(Y) \geq 0.$$

这是关于 t 的二次非负式, 判别式 ≤ 0 :

$$[2\text{Cov}(X, Y)]^2 - 4D(X)D(Y) \leq 0 \implies \text{Cov}(X, Y)^2 \leq D(X)D(Y).$$

即 $|\rho_{XY}| \leq 1$. 等号成立 $\iff Z = 0$ a.s. $\iff Y$ 是 X 的线性函数。

独立与不相关的等价条件

- 独立 $\implies$ 不相关 ($\rho = 0$), 反之不成立;
- 二维正态分布: 独立 $\iff$ 不相关 ($\rho = 0$);
- 不相关 $\iff \text{Cov}(X, Y) = 0 \iff E(XY) = E(X)E(Y) \iff D(X \pm Y) = D(X) + D(Y)$.

3.3 随机变量和的期望与方差

和的数字特征

期望 (无条件): $E(X + Y) = E(X) + E(Y)$ 。

方差:

$$D(X + Y) = D(X) + D(Y) + 2\text{Cov}(X, Y), \quad D(X - Y) = D(X) + D(Y) - 2\text{Cov}(X, Y).$$

独立时: $D(X \pm Y) = D(X) + D(Y)$ 。

样本均值的数字特征: $X_1, \dots, X_n$ 独立同分布, $E(X_i) = \mu$, $D(X_i) = \sigma^2$:

$$E(\bar{X}) = \mu, \quad D(\bar{X}) = \frac{\sigma^2}{n}, \quad E(S^2) = \sigma^2.$$

$E(S^2) = \sigma^2$ 的证明 (无偏性)

$$\begin{aligned} \sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n [(X_i - \mu) - (\bar{X} - \mu)]^2 \\ &= \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2. \end{aligned}$$

取期望:

$$E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2.$$

故 $E(S^2) = E\left[\frac{1}{n-1} \sum (X_i - \bar{X})^2\right] = \sigma^2$ (无偏)。

若除以 n (即 B_2), 则 $E(B_2) = \frac{n-1}{n}\sigma^2 \neq \sigma^2$ (有偏)。

第 4 章 大数定律与中心极限定理

4.1 切比雪夫不等式的应用与变形

切比雪夫不等式的变形

标准形式:

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{D(X)}{\varepsilon^2}.$$

等价形式:

$$P(|X - E(X)| < \varepsilon) \geq 1 - \frac{D(X)}{\varepsilon^2}.$$

取 $\varepsilon = k\sqrt{D(X)}$ (k 倍标准差):

$$P(|X - E(X)| \geq k\sqrt{D(X)}) \leq \frac{1}{k^2}.$$

应用于样本均值: $X_1, \dots, X_n$ 独立同分布, $E(X_i) = \mu$, $D(X_i) = \sigma^2$:

$$P(|\bar{X} - \mu| \geq \varepsilon) \leq \frac{D(\bar{X})}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

切比雪夫不等式推导

设 X 的期望 μ , 方差 σ^2 , 密度 $f(x)$ (离散型类似)。

$$\begin{aligned} D(X) &= \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx \\ &\geq \int_{|x - \mu| \geq \varepsilon} (x - \mu)^2 f(x) dx \quad (\text{缩小积分域}) \\ &\geq \int_{|x - \mu| \geq \varepsilon} \varepsilon^2 f(x) dx \quad (|x - \mu|^2 \geq \varepsilon^2) \\ &= \varepsilon^2 P(|X - \mu| \geq \varepsilon). \end{aligned}$$

移项得 $P(|X - \mu| \geq \varepsilon) \leq \frac{D(X)}{\varepsilon^2}$ 。

应用场景

切比雪夫不等式用于估计概率范围 (不知分布只知期望方差时); 考研中常用于证明题或估计题, 注意它给出的是上界, 实际概率通常更小。

4.2 中心极限定理的标准化变形

中心极限定理的实用形式

一般形式 (独立同分布): $X_1, \dots, X_n$ 独立同分布, $E(X_i) = \mu$, $D(X_i) = \sigma^2$:

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \sim N(0, 1) \quad (n \text{ 大}).$$

样本均值形式:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), \quad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

二项分布形式 (棣莫弗-拉普拉斯): $Y_n \sim B(n, p)$:

$$\frac{Y_n - np}{\sqrt{np(1-p)}} \sim N(0, 1).$$

频率形式:

$$\frac{n_A/n - p}{\sqrt{p(1-p)/n}} \sim N(0, 1).$$

棣莫弗-拉普拉斯定理是 CLT 的特例

设 X_i 为第 i 次伯努利试验的结果 ($X_i \sim B(1, p)$), 则 $Y_n = \sum_{i=1}^n X_i \sim B(n, p)$ 。 $E(X_i) = p$, $D(X_i) = p(1-p)$, 由 CLT:

$$\frac{\sum X_i - np}{\sqrt{np(1-p)}} = \frac{Y_n - np}{\sqrt{np(1-p)}} \sim N(0, 1).$$

CLT 解题模板

四步法:

1. 识别独立同分布序列 $X_1, \dots, X_n$, 计算 $\mu = E(X_i)$, $\sigma^2 = D(X_i)$;
2. 写出和 $S_n = \sum X_i$ 或均值 $\bar{X}$;
3. 标准化: $Z = \frac{S_n - n\mu}{\sqrt{n}\sigma}$ 或 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$;
4. 用 Φ 表查值: $P(a < S_n < b) \approx \Phi\left(\frac{b - n\mu}{\sqrt{n}\sigma}\right) - \Phi\left(\frac{a - n\mu}{\sqrt{n}\sigma}\right)$ 。

易错: 标准化分母

常见错误: 分母写成 σ 或 $n\sigma$ 。**正确:** 和的标准化分母为 $\sqrt{n}\sigma = \sqrt{n\sigma^2} = \sqrt{D(\sum X_i)}$; 均值的标准化分母为 $\sigma/\sqrt{n} = \sqrt{D(\bar{X})}$ 。**记忆口诀:** "标准化 = (统计量 - 期望) / 标准差"。

第 5 章 数理统计的基本概念

5.1 三大抽样分布的构造与性质

三大分布的构造与可加性

χ^2 分布:

- 构造: $X_1, \dots, X_n \sim N(0, 1)$ 独立 $\Rightarrow \sum X_i^2 \sim \chi^2(n)$;
- 期望方差: $E = n$, $D = 2n$;
- 可加性: $\chi_1^2(n_1) + \chi_2^2(n_2) \sim \chi^2(n_1 + n_2)$ (独立时);
- 变形: $\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$ (μ, σ 已知)。

t 分布:

- 构造: $X \sim N(0, 1)$, $Y \sim \chi^2(n)$ 独立 $\Rightarrow T = \frac{X}{\sqrt{Y/n}} \sim t(n)$;
- 对称性: 关于 y 轴对称, $t_{1-\alpha}(n) = -t_\alpha(n)$;
- 极限: $t(n) \xrightarrow{d} N(0, 1)$ ($n \rightarrow \infty$, 一般 $n > 30$ 可用正态近似)。

F 分布:

- 构造: $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$ 独立 $\Rightarrow F = \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$;
- 倒数: $\frac{1}{F} \sim F(n_2, n_1)$;
- 分位点: $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_\alpha(n_2, n_1)}$ 。

单正态总体抽样分布的推导

设 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ 。

(1) $\bar{X}$ 的分布: 正态分布线性组合仍正态:

$$\bar{X} = \frac{1}{n} \sum X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

(2) $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$:

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma}\right)^2 + n \left(\frac{\bar{X} - \mu}{\sigma}\right)^2.$$

左边 $\sim \chi^2(n)$, 右边第二项 $\sim \chi^2(1)$, 且二者独立 ($\bar{X}$ 与 S^2 独立), 故

$$\sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma}\right)^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

(3) $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad \text{二者独立.}$$

由 t 分布构造:

$$\frac{(\bar{X} - \mu)/(\sigma/\sqrt{n})}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

$\bar{X}$ 与 S^2 独立的重要性

重要结论: 正态总体下, $\bar{X}$ 与 S^2 相互独立。这是构造 t 统计量的关键, 也是置信区间和假设检验的理论基础。非正态总体此结论不成立。

5.2 样本方差的两种定义对比

S^2 与 B_2 的关系

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

关系:

$$B_2 = \frac{n-1}{n} S^2, \quad S^2 = \frac{n}{n-1} B_2.$$

无偏性:

$$E(S^2) = \sigma^2 (\text{无偏}), \quad E(B_2) = \frac{n-1}{n} \sigma^2 (\text{有偏}).$$

渐近性: $n \rightarrow \infty$ 时 $B_2 \rightarrow S^2 \rightarrow \sigma^2$ 。

何时用哪个

区间估计与假设检验中用 S^2 (无偏); 矩估计中用 $B_2 = A_2 - \bar{X}^2$ (按定义); 最大似然估计中视具体分布而定 (正态总体 MLE 为 B_2)。

第 6 章 参数估计

6.1 矩估计的求解流程

矩估计的一般步骤

单参数: 令 $E(X) = \bar{X}$ (一阶矩等于样本一阶矩), 解出参数。

双参数: 令方程组

$$\begin{cases} E(X) = \bar{X} = A_1, \\ E(X^2) = A_2 = \frac{1}{n} \sum X_i^2, \end{cases}$$

解出两个参数。也可用 $D(X) = E(X^2) - [E(X)]^2$ 配合。

变形 (用方差): 若参数与方差有关, 可令 $D(X) = B_2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 。

正态总体 $N(\mu, \sigma^2)$ 的矩估计

令

$$\begin{cases} E(X) = \bar{X} \implies \mu = \bar{X}, \\ E(X^2) = A_2 \implies \mu^2 + \sigma^2 = A_2. \end{cases}$$

代入 $\hat{\mu} = \bar{X}$:

$$\hat{\sigma}^2 = A_2 - \bar{X}^2 = \frac{1}{n} \sum X_i^2 - \bar{X}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 = B_2.$$

注意: 矩估计 $\hat{\sigma}^2 = B_2$ (有偏), 与无偏估计 S^2 不同。

常见分布的矩估计

- $B(n, p)$ (n 已知): $\hat{p} = \bar{X}/n$;
- $P(\lambda)$: $\hat{\lambda} = \bar{X}$ (也可用 S^2 , 因 $E = D = \lambda$);
- $U(a, b)$: $\hat{a} = \bar{X} - \sqrt{3}S_n$, $\hat{b} = \bar{X} + \sqrt{3}S_n$ ($S_n^2 = B_2$);
- $\text{Exp}(\lambda)$: $\hat{\lambda} = \frac{1}{\bar{X}}$;
- $N(\mu, \sigma^2)$: $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = B_2$ 。

6.2 最大似然估计的求解流程

MLE 求解步骤

步骤 1: 构造似然函数

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) (\text{连续}), \quad L(\theta) = \prod_{i=1}^n P(X = x_i; \theta) (\text{离散}).$$

步骤 2: 取对数 $\ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta)$ 。

步骤 3: 求导令其为零 $\frac{\partial \ln L}{\partial \theta} = 0$, 解出 $\hat{\theta}$ 。

步骤 4 (验证): 确认是最大值 (二阶导 < 0 或单调性分析)。

变形 (无导数法): 若 $L(\theta)$ 关于 θ 单调或不可导, 直接求 L 的最大值点。例如 $U(0, \theta)$ 的 MLE 为 $\hat{\theta} = X_{(n)} = \max X_i$ (不能用求导法)。

正态总体 $N(\mu, \sigma^2)$ 的 MLE

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = (2\pi\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2}.$$

取对数:

$$\ln L = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2.$$

分别对 μ, σ^2 求偏导令其为零:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum (x_i - \mu) = 0 \implies \hat{\mu} = \bar{X}.$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2 = 0 \implies \hat{\sigma}^2 = \frac{1}{n} \sum (x_i - \bar{X})^2 = B_2.$$

结论: 正态总体 MLE $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = B_2$ (有偏)。

MLE 的不变性

若 $\hat{\theta}$ 是 θ 的 MLE, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE (g 为单值函数, 不必单调)。例: 正态总体 σ 的 MLE 为 $\hat{\sigma} = \sqrt{B_2}$ (不是 S)。

6.3 区间估计的构造原理

区间估计的”枢轴量”法

核心思想: 构造枢轴量 $G = G(\theta, X_1, \dots, X_n)$, 其分布不依赖 θ , 由分布表查分位点, 反解出 θ 的区间。

正态总体枢轴量汇总:

情形	枢轴量	分布
σ^2 已知, 估 μ	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$	$N(0, 1)$
σ^2 未知, 估 μ	$\frac{\bar{X} - \mu}{S/\sqrt{n}}$	$t(n-1)$
μ 未知, 估 σ^2	$\frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$
μ 已知, 估 σ^2	$\frac{\sum (X_i - \mu)^2}{\sigma^2}$	$\chi^2(n)$

σ^2 置信区间的推导

枢轴量 $Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, 分布不依赖 σ^2 。由 $P(\chi_{1-\alpha/2}^2(n-1) \leq Q \leq \chi_{\alpha/2}^2(n-1)) = 1 - \alpha$, 即

$$\chi_{1-\alpha/2}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2}^2.$$

反解 σ^2 (注意不等式方向反转, 因 σ^2 在分母):

$$\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}.$$

关键: χ^2 分布右偏, $\chi_{\alpha/2}^2 > \chi_{1-\alpha/2}^2$, 故大分位点对应小区间端点。

分位点记忆口诀

z/t 区间: 对称分布, $\bar{X} \mp (\text{分位点}) \times (\text{标准误})$; χ^2 区间: 非对称, $(n-1)S^2$ 在分子, 分母是 $\chi_{\alpha/2}^2$ (小端) 和 $\chi_{1-\alpha/2}^2$ (大端), **大分位点对应左端点**。

第 7 章 假设检验

7.1 假设检验与区间估计的对偶关系

检验与置信区间的对偶

对偶原理：参数 θ 的水平 $1 - \alpha$ 置信区间 C 与显著性水平 α 的双侧检验 $H_0 : \theta = \theta_0$ 对应：

$$\theta_0 \in C \iff \text{接受 } H_0.$$

对应关系表 (单正态总体)：

检验	统计量	对应置信区间
σ^2 已知检 μ	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$\bar{X} \mp z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
σ^2 未知检 μ	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$\bar{X} \mp t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}$
μ 未知检 σ^2	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2} \right)$

对偶关系的应用

已知置信区间 $\Rightarrow$ 判断检验：若 μ_0 落在 μ 的 $1 - \alpha$ 置信区间内，则在水平 α 下接受 $H_0 : \mu = \mu_0$ ；否则拒绝。**已知检验结果 $\Rightarrow$ 构造区间：**接受域即为置信区间。

7.2 单侧检验与双侧检验的拒绝域

拒绝域的确定规则

双侧检验 $H_1 : \theta \neq \theta_0$ ：拒绝域在两侧，用 $\alpha/2$ 分位点。**单侧检验** $H_1 : \theta > \theta_0$ (右侧)：拒绝域在右侧，用 α 分位点。**单侧检验** $H_1 : \theta < \theta_0$ (左侧)：拒绝域在左侧，用 α 分位点。

单正态总体均值检验拒绝域：

H_1	σ^2 已知 (Z 检验)	σ^2 未知 (t 检验)
$\mu \neq \mu_0$	$ Z > z_{\alpha/2}$	$ T > t_{\alpha/2}(n-1)$
$\mu > \mu_0$	$Z > z_{\alpha}$	$T > t_{\alpha}(n-1)$
$\mu < \mu_0$	$Z < -z_{\alpha}$	$T < -t_{\alpha}(n-1)$

方差检验拒绝域 (μ 未知)：

- $H_1 : \sigma^2 \neq \sigma_0^2$ ： $\chi^2 > \chi_{\alpha/2}^2(n-1)$ 或 $\chi^2 < \chi_{1-\alpha/2}^2(n-1)$ ；
- $H_1 : \sigma^2 > \sigma_0^2$ ： $\chi^2 > \chi_{\alpha}^2(n-1)$ ；
- $H_1 : \sigma^2 < \sigma_0^2$ ： $\chi^2 < \chi_{1-\alpha}^2(n-1)$ 。

双侧与单侧分位点的关系

双侧检验将 α 平分到两侧，每侧 $\alpha/2$ ，故用 $z_{\alpha/2}$ (满足 $P(Z > z_{\alpha/2}) = \alpha/2$)。单侧检验将全部 α 放一侧，故用 z_{α} (满足 $P(Z > z_{\alpha}) = \alpha$)。**关系：** $z_{\alpha/2} > z_{\alpha}$ (双侧临界值更大，更难拒绝)。

7.3 两类错误与功效函数

两类错误的关系

第一类错误 (弃真): $\alpha = P(\text{拒}H_0 | H_0\text{真})$; **第二类错误 (取伪):** $\beta = P(\text{接}H_0 | H_0\text{假})$; **功效 (1 - 第二类错误):** $1 - \beta = P(\text{拒}H_0 | H_0\text{假})$ 。

关系: 样本量固定时, $\alpha \downarrow \Rightarrow \beta \uparrow$; 要同时减小 α, β , 需增大样本量 n 。

显著性水平: α 是犯第一类错误的上限, 由检验者事先指定。

β 的计算示例

设 $X \sim N(\mu, 1)$, $H_0: \mu = 0$ vs $H_1: \mu = 1$, $n = 25$, $\alpha = 0.05$ 。检验统计量 $Z = \frac{\bar{X} - 0}{1/\sqrt{25}} = 5\bar{X}$, 拒绝域 $|Z| > z_{0.025} = 1.96$, 即 $\bar{X} > 0.392$ 或 $\bar{X} < -0.392$ 。

当 H_1 真 ($\mu = 1$) 时, $\bar{X} \sim N(1, 1/25)$, $Z = 5\bar{X} \sim N(5, 1)$:

$\beta = P(\text{接}H_0 | \mu = 1) = P(-0.392 \leq \bar{X} \leq 0.392 | \mu = 1) = P(-1.96 \leq Z' \leq 0.392 \times 5 - 5 | Z' \sim N(5, 1))$ 。

即 $\beta = \Phi(0) - \Phi(-5 \times 1 + 1.96) \approx 0.5 - 0 = \text{极小}$ (此处简化说明思路)。

考研重点

常考: (1) 给定 α 求拒绝域; (2) 计算检验统计量观测值判断; (3) β 的计算 (较少但需掌握思路); (4) 对偶关系 (置信区间判断检验)。**易错:** 单侧检验方向由 H_1 决定, 不是由样本决定; F 检验约定大方差放分子。

第 8 章 综合应用与跨模块联系

8.1 正态分布在各模块的贯穿

正态分布的核心地位

正态分布贯穿概率统计各模块:

1. **概率计算:** 标准化查 Φ 表;
2. **数字特征:** $E = \mu$, $D = \sigma^2$, 线性变换仍正态;
3. **中心极限定理:** 独立同分布和的极限分布为正态;
4. **抽样分布:** χ^2, t, F 均由正态变量构造;
5. **参数估计:** 正态总体区间估计与假设检验体系完整;
6. **二维正态:** 独立 $\iff$ 不相关 (唯一例外)。

8.2 独立同分布条件的统一理解

独立同分布的应用场景

辛钦大数定律: 独立同分布 $\Rightarrow \bar{X} \xrightarrow{P} \mu$ (矩估计理论依据)。

中心极限定理: 独立同分布 $\Rightarrow \bar{X} \sim N(\mu, \sigma^2/n)$ (近似计算依据)。

抽样分布: 样本 $X_1, \dots, X_n$ 独立同分布 (来自同一总体) $\Rightarrow$ 构造 χ^2, t, F 。

最大似然估计: 独立同分布 $\Rightarrow L(\theta) = \prod f(x_i; \theta)$ (似然函数构造)。

联系: 独立同分布是统计推断的**基本假设**, 贯穿大数定律、中心极限定理、抽样分布、参数估计四大模块。

8.3 考研高频题型与公式对应

高频题型公式速查

1. **求概率 (古典/几何/公式):** 加法、乘法、全概率、贝叶斯;
2. **求分布 (函数的分布):** 分布函数法、公式法 (单调可导);
3. **求期望方差:** 定义法、性质法、分解法 ($X = X_1 + \dots + X_n$);
4. **协方差与相关系数:** $\text{Cov} = E(XY) - E(X)E(Y)$, $\rho = \text{Cov}/(\sigma_X\sigma_Y)$;
5. **切比雪夫估计:** $P(|X - \mu| \geq \varepsilon) \leq \sigma^2/\varepsilon^2$;
6. **CLT 近似计算:** 标准化 + 查 Φ 表;
7. **抽样分布识别:** 正态 $\rightarrow \chi^2 \rightarrow t \rightarrow F$ 的构造链;
8. **矩估计/MLE:** 构造方程组/似然函数, 求导令零;
9. **区间估计:** 枢轴量法, 查分位点;
10. **假设检验:** 选统计量, 定拒绝域, 判断。